

# **SPRAWOZDANIE**

Zajęcia: Analiza Procesów Uczenia

Prowadzący: prof. dr hab. Vasyl Martsenyuk

## **Laboratorium 4.2**

05.01.2022

**Temat: Modelowanie procesów uczenia maszynowego w pakiecie mlr.  
Trenowanie, ocena i porównywanie modeli w pakiecie mlr**

**Wariant 7**


Smolec Bartłomiej

Informatyka II stopień  
niestacjonarne (zaoczne)

1 semestr

## 1 . Polecenie

**Zadanie** dotyczy prognozowania oceny klientów (w skali 5-punktowej, Error < 5%) urządzeń RTV AGD, określonych na Zajęciu 1. Rozwiązanie polega na użyciu pakietu mlr. Należy wybrać najlepszą metodę wśród 5 możliwych z punktu widzenia precyzyjności. Wyniki porównywania precyzyjności metod należy przedstawić w postaci graficznej.

 Przykład MLR.R

## 2. Rozwiązanie

Link do github: <https://github.com/barteksmolec12/APU4>

*Konfiguracja bibliotek*

```
install.packages("randomForest")
install.packages("e1071")
install.packages("party")
install.packages("mlr")
install.packages("rFerts")

library(randomForest)
library(rpart.plot)
library(party)
library(mlr)
library(rFerts)
```

*Ładowanie danych (zbiór danych z pierwszych zajęć)*

```
ipady_rtv=read.csv("ramka_dane.csv")|
ipady_rtv$tablet = factor(ipady_rtv$tablet)
ipady_rtv$ocena = factor(ipady_rtv$ocena)
```

	X	tablet	modem	wyswietlacz	pamiec_ram	pamiec_wbudowana	cena	liczba_opinii	ocena	status_opinii
1	1	iPad 1 iOS 9 2Ghz	LTE	10"	2 GB	64 GB	1700	19	5	nie ma
2	2	iPad 2s iOS 9 2Ghz	3G	10"	6 GB	64 GB	4500	44	3.5	mniej 50 opinii
3	3	iPad 3S iOS 9 2Ghz	2G	9"	6 GB	128 GB	2000	30	4.5	50-100 opinii
4	4	iPad mini iOS 9 2Ghz	4G	10"	3 GB	128 GB	1700	100	4.5	wiecej niż 100 op
5	5	iPad pro iOS 9 2Ghz	LTE	9,5"	6,5 GB	128 GB	2099	123	2	nie ma

## Operacje na danych

```
ipady_rtv=read.csv("ramka_dane.csv")
ipady_rtv$tablet = factor(ipady_rtv$tablet)
ipady_rtv$ocena = factor(ipady_rtv$ocena)

summarizeColumns(ipady_rtv)

rdesc = makeResampleDesc("CV", iters = 10)


task = makeClassifTask(id = deparse(substitute(ipady_rtv)), ipady_rtv, "ocena",
                        weights = NULL, blocking = NULL, coordinates = NULL,
                        positive = NA_character_, fixup.data = "warn", check.data = TRUE)
lrns <- makeLearners(c("rpart", "C50", "ctree", "naiveBayes", "randomForest"), type = "classif")

bmr <- benchmark(learners = lrns, tasks = task, rdsc, models = TRUE, measures = list(acc, ber))
p = getBMRPredictions(bmr)
plotBMRSummary(bmr)
```

### Resampling: cross-validation

Measures:	acc	ber
[Resample] iter 1:	0.5000000	NaN
[Resample] iter 2:	0.0000000	NaN
[Resample] iter 3:	0.0000000	NaN
[Resample] iter 4:	0.5000000	NaN
[Resample] iter 5:	0.0000000	NaN
[Resample] iter 6:	1.0000000	NaN
[Resample] iter 7:	1.0000000	NaN
[Resample] iter 8:	0.0000000	NaN
[Resample] iter 9:	0.5000000	NaN
[Resample] iter 10:	0.0000000	NaN

### Wizualizacja w formie graficznej



### 3. Wnioski

Utworzone zadanie pozwoliło mi zapoznać się z pakietem mlr.